

BAHAN_AJAR_Pertemuan02

BAHAN AJAR - PERTEMUAN 2 (S2)

Data Cleansing & Labeling

TP	BK, AD — Pengolahan Data Bervolume Besar
----	--

A. MASALAH KUALITAS DATA

1. Missing Values

Data kosong — tidak diisi saat pengumpulan.

Penyebab	Contoh	Solusi
Responden tidak mau jawab	Survey: “Pendapatan?”	Isi dengan median
Error input	Sensor mati	Hapus baris tersebut
Tidak relevan	Pria → hamil?	Biarkan kosong (NA)

Dampak: - Rata-rata jadi bias - Fungsi `AVERAGE` mengabaikan kosong (tapi jumlah sampel berkurang) - Machine learning error

2. Duplicates

Data yang sama muncul lebih dari sekali.

Penyebab	Contoh
Error input ganda	“Budi” diinput 2×
Merge data dari sumber berbeda	Database A + Database B ada nama sama
Crawling/scraping ganda	Web scraping ambil halaman sama 2×

3. Outliers

Nilai yang sangat berbeda dari mayoritas data.

Outlier	Contoh	Deteksi
Nilai 1000 (skala 0–100)	Kesalahan input	Filter + sort
Suhu 500°C di Indonesia	Sensor error	IQR: $Q1 - 1.5IQR$ s.d. $Q3 + 1.5IQR$
Usia 200 tahun	Tidak wajar	Domain knowledge: usia max 120

4. Inconsistent Data

Format yang tidak seragam.

Kolom	Data Kotor	Standarisasi
-------	------------	--------------

Kolom	Data Kotor	Standarisasi
Nama	"budi", "Budi", "BUDI", "budi santoso"	=PROPER() → "Budi Santoso"
Kelas	"X-A", " X-A", "XA", "10A", "X A"	Semua → "X-A"
Tanggal	"1/1/2026", "2026-01-01", "01-Jan-26"	Format ISO: 2026-01-01
Alamat	"Jl.Merdeka", "Jalan Merdeka", "Jl. Merdeka"	Satu format: "Jl. Merdeka"

B. TEKNIK DATA CLEANING

Panduan Lengkap Google Sheets

Tujuan	Langkah	Rumus / Menu
Cek missing	Filter kolom → cek (Blanks)	=ISBLANK(A2)
Isi missing (angka)	Cari rata-rata → isi	=IF(ISBLANK(A2), AVERAGE(A:A), A2)
Hapus baris kosong	Filter blok → Delete rows	Data → Create filter
Cek duplikat	Conditional formatting	Format → CF → =COUNTIF(A:A,A1)>1
Hapus duplikat	Data cleanup	Data → Data cleanup → Remove duplicates
Standarisasi teks	Ubah ke format seragam	=UPPER(), =LOWER(), =PROPER(), =TRIM()
Hapus spasi berlebih	Trim	=TRIM(A2)
Split kolom	Pisah data	Data → Split text to columns
Validasi data	Batasi input	Data → Data validation

Mengukur "Kebersihan" Data

Metrik	Arti	Target
Completeness	% data tidak kosong	> 95%
Uniqueness	% data unik	> 90%
Validity	% data valid (format benar)	> 98%
Consistency	% data konsisten format	100%

C. DATA LABELING

Definisi

Labeling = memberi label/kategori pada data mentah sehingga bisa digunakan untuk supervised machine learning.

Jenis Labeling

Jenis	Deskripsi	Contoh
Biner	2 kelas	Spam / Not Spam
Multi-class	> 2 kelas	Sentimen: Pos / Neu / Neg
Multi-label	1 data → banyak label	Foto: [kucing, outdoor, siang]
Regression	Nilai kontinu	Harga rumah: Rp 500.000.000

Contoh Labeling — Sentimen

Komentar	Label
“Produknya bagus sekali!”	Positif
“Pengiriman lambat”	Negatif
“Barang sesuai deskripsi”	Netral
“Mantap! rekomen!”	Positif
“Biasa aja sih”	Netral

Inter-Annotator Agreement

Dua orang labeler bisa berbeda pendapat. Semakin tinggi kesepakatan → semakin baik kualitas label.

Agreement	Kualitas Label	Tindakan
> 90%	Sangat baik	Gunakan langsung
70–90%	Baik	Diskusikan perbedaan
< 70%	Buruk	Perbaiki panduan labeling

Tools Labeling

Tool	Kelebihan
Google Sheets	Sederhana, manual
Label Studio	Open source, banyak format
Prodigy	Cepat, active learning
Roboflow	Labeling gambar

D. STUDI KASUS: CLEANING DATASET PENDUDUK

Dataset dari data.go.id “Jumlah Penduduk per Provinsi 2025”

Masalah	Contoh Data Kotor	Tindakan Cleaning
Nama provinsi inkonsisten	“DKI JAKARTA”, “Jakarta”, “DKI Jakarta”	=PROPER() + standardisasi
Kode provinsi kosong	1 baris kosong	Isi dengan kode yang sesuai

Masalah	Contoh Data Kotor	Tindakan Cleaning
Jumlah penduduk -500	Minus	Validasi sumber → isi ulang
Duplikat	"Jawa Barat" 2 baris	Hapus duplikat, jumlahkan
Format angka	"45.000.000" vs "45000000"	Hapus titik, format number

E. RANGKUMAN

Langkah	Teknik
1. Identifikasi masalah	Missing, duplikat, outlier, inkonsisten
2. Cleaning	ISBLANK, COUNTIF, TRIM, PROPER, Remove duplicates
3. Validasi	Cek completeness, uniqueness, validity
4. Labeling	Beri label → siap untuk ML
5. Dokumentasi	Catat setiap perubahan

Prinsip: Garbage In, Garbage Out!

MGMP Informatika SMAN 6 Cimahi