

Slide Pert 2 S2

PERTEMUAN 2 — FASE F (S2)

Data Cleansing & Labeling

Informatika - Fase F / Kelas XI

SMA Negeri 6 Cimahi

Review — Pert 1

Sumber data legal → data.go.id

Tapi data masih KOTOR!

Garbage In, Garbage Out! 🗑️

Tujuan Pembelajaran

1. Identifikasi masalah data

2. Data cleaning (Sheets)
 3. Konsep labeling
 4. Praktik labeling sentimen
-

Masalah Kualitas Data

1. Missing Values

Data kosong / tidak diisi

Nilai: 80, 75, , 90, 85
↑ kosong!

Solusi: Isi rata-rata / hapus baris

2. Duplicates

Data sama muncul 2× atau lebih

"Budi Santoso" – baris 5
"Budi Santoso" – baris 23 → HAPUS!

Solusi: Data → Remove duplicates

3. Outliers

Nilai yang tidak wajar

Nilai UTS: 80, 75, 90, 85, 1000, 70
↑ OUTLIER!

Solusi: Filter → sort → cek nilai ekstrem

4. Inconsistent Data

Format tidak seragam

```
Nama: "budi", "Budi", "BUDI"  
Kelas: "X-A", " X-A", "XA", "10A"
```

Solusi: =PROPER() , =TRIM() , standarisasi

TEKNIK CLEANING

Google Sheets Cleaning

Masalah	Cara
Cek missing	<code>=ISBLANK(A2)</code>
Hapus duplikat	Data → Remove duplicates
Standarisasi	<code>=PROPER()</code> , <code>=UPPER()</code> , <code>=LOWER()</code>
Bersihkan spasi	<code>=TRIM()</code>
Deteksi outlier	Filter → sort

Sebelum vs Sesudah

SEBELUM:	SESUDAH:
100 baris	95 baris (-5 duplikat)
5 kosong	0 kosong (isi rata-rata)
3 outlier	0 outlier (koreksi)
Campur aduk	Seragam

Data bersih = analisis akurat!

DATA LABELING

Apa itu Labeling?

Memberi label/kategori pada data mentah untuk ML

"Produk bagus!" → Positif
"Pengiriman lama" → Negatif
"Barang sesuai" → Netral

Jenis Labeling

Biner : Spam / Bukan
Multi-class : Pos / Neu / Neg
Multi-label : [kucing, outdoor]
Regression : Harga Rp 500jt

Aktivitas 1 — Cleaning

35 menit — Individu

Dataset kotor → bersihkan!

Missing → Duplikat → Outlier → Standarisasi

Buat sheet "Hasil Cleaning"

Aktivitas 2 — Labeling

25 menit — Berpasangan

Label 10 komentar sekolah:

Komentar	Label?
----------	--------

Komentar	Label?
"Sekolahku keren!"	?
"Tugasnya banyak"	?
"Biasa aja"	?

Bandingkan!

Cocokkan label dengan kelompok lain!

Kalau beda → diskusi, kenapa?

Refleksi

- Masalah data paling sering ditemui?
- Teknik cleaning favorit?
- Skala 1-10?

Preview — Pert 3

Visualisasi Data & Dashboard

Dashboard keren dari data bersih!

Terima Kasih

MGMP Informatika SMAN 6 Cimahi

"Data bersih = analisis akurat = keputusan tepat!"