

BAHAN_AJAR_Pertemuan14

BAHAN AJAR - PERTEMUAN 14 (S2)

Proyek Akhir — Pipeline Pengolahan Data dengan Python

TP	Pengolahan Data Bervolume Besar
----	---------------------------------

A. PIPELINE PENGOLAHAN DATA

Diagram Alur

DATA KOTOR → LOAD → EXPLORE → CLEAN → TRANSFORM → ANALYZE → VISUALIZE → EXPORT
--

Library yang Digunakan

Library	Fungsi	Install
pandas	Baca, manipulasi, analisis data	pip install pandas
matplotlib	Visualisasi grafik	pip install matplotlib

B. KODE REFERENSI LENGKAP

1. Load & Explore

<pre>import pandas as pd import matplotlib.pyplot as plt # Load CSV df = pd.read_csv('nilai_siswa.csv') # Lihat 5 baris pertama print("=== 5 BARIS PERTAMA ===") print(df.head()) # Informasi dataset print("\n=== INFO DATASET ===") print(df.info()) # Statistik deskriptif print("\n=== DESKRIPSI STATISTIK ===") print(df.describe()) # Cek missing value print("\n=== MISSING VALUE ===") print(df.isnull().sum()) # Cek duplikat print(f"\nJUMLAH DUPLIKAT: {df.duplicated().sum()}")</pre>

2. Clean

```
# Hapus duplikat
df = df.drop_duplicates()

# Isi missing value dengan mean
df['Matematika'] = df['Matematika'].fillna(df['Matematika'].mean())

# Perbaiki outlier
df.loc[df['Informatika'] > 100, 'Informatika'] = 100

# Konversi ke integer
df['Matematika'] = df['Matematika'].astype(int)

# Verifikasi
print(df.isnull().sum())
print(df.describe())
```

3. Transform

```
# Daftar mapel
mapel = ['Matematika', 'B_Indonesia', 'B_Ingggris', 'Informatika', 'IPA', 'IPS']

# Rata-rata
df['Rata_rata'] = df[mapel].mean(axis=1)

# Total
df['Total'] = df[mapel].sum(axis=1)

# Grade
def grade(rata):
    if rata >= 90: return 'A'
    elif rata >= 80: return 'B'
    elif rata >= 70: return 'C'
    elif rata >= 60: return 'D'
    else: return 'E'

df['Grade'] = df['Rata_rata'].apply(grade)

# Status
def status(rata):
    return 'LULUS' if rata >= 70 else 'REMIDI'

df['Status'] = df['Rata_rata'].apply(status)

print(df[['Nama', 'Rata_rata', 'Grade', 'Status']].head(10))
```

4. Analyze

```

# Rata-rata per kelas
print("=== RATA-RATA PER KELAS ===")
print(df.groupby('Kelas')[mapel + ['Rata_rata']].mean().round(1))

# Top 5
print("\n=== TOP 5 SISWA ===")
print(df.sort_values('Rata_rata', ascending=False)[['Nama', 'Kelas', 'Rata_rata', 'Grade']].head(5))

# Bottom 5
print("\n=== BOTTOM 5 ===")
print(df.sort_values('Rata_rata')[['Nama', 'Kelas', 'Rata_rata', 'Grade']].head(5))

# Distribusi grade
print(f"\n=== DISTRIBUSI GRADE ===")
print(df['Grade'].value_counts().sort_index())

# Jumlah remidi
print(f"\nJUMLAH REMIDI: {df[df['Status'] == 'REMIDI'].shape[0]}")

```

5. Visualize

```

# 1. Bar chart – rata-rata per mapel
plt.figure(figsize=(10, 5))
rata_mapel = df[mapel].mean()
warna = ['#FF6B6B', '#4ECDC4', '#45B7D1', '#96CEB4', '#FFEEA7', '#DDA0DD']
plt.bar(mapel, rata_mapel, color=warna)
plt.title('Rata-rata Nilai per Mapel', fontsize=14, fontweight='bold')
plt.ylabel('Nilai', fontsize=11)
plt.ylim(0, 100)
for i, v in enumerate(round(rata_mapel, 1)):
    plt.text(i, v + 1, str(v), ha='center', fontsize=10)
plt.tight_layout()
plt.savefig('rata_mapel.png', dpi=150)
plt.show()

# 2. Pie – distribusi grade
plt.figure(figsize=(7, 7))
grade_counts = df['Grade'].value_counts()
warna_grade = {'A': '#FFD700', 'B': '#98FB98', 'C': '#87CEEB', 'D': '#FFA07A', 'E': '#FF6B6B'}
colors = [warna_grade[g] for g in grade_counts.index]
plt.pie(grade_counts, labels=[f"{g} ({c})" for g, c in zip(grade_counts.index, grade_counts.values)],
        colors=colors, autopct='%1.1f%%', startangle=90, textprops={'fontsize': 11})
plt.title('Distribusi Grade', fontsize=14, fontweight='bold')
plt.savefig('distribusi_grade.png', dpi=150)
plt.show()

# 3. Scatter – Matematika vs Informatika
plt.figure(figsize=(8, 6))
colors = ['green' if s == 'LULUS' else 'red' for s in df['Status']]
plt.scatter(df['Matematika'], df['Informatika'], c=colors, alpha=0.6, s=60)
plt.xlabel('Matematika', fontsize=11)
plt.ylabel('Informatika', fontsize=11)
plt.title('Korelasi Matematika vs Informatika', fontsize=14, fontweight='bold')
plt.grid(True, alpha=0.3)
plt.savefig('korelasi.png', dpi=150)
plt.show()

# 4. Boxplot – distribusi nilai per mapel
plt.figure(figsize=(10, 6))
df[mapel].boxplot()
plt.title('Distribusi Nilai per Mapel', fontsize=14, fontweight='bold')
plt.ylabel('Nilai', fontsize=11)
plt.grid(True, alpha=0.3)
plt.savefig('boxplot_nilai.png', dpi=150)
plt.show()

```

6. Export

```
# Data bersih
df.to_csv('nilai_siswa_bersih.csv', index=False)

# Statistik
df[mapel].describe().to_csv('statistik_nilai.csv')

# Rata-rata per kelas
df.groupby('Kelas')[mapel + ['Rata_rata']].mean().round(1).to_csv('rata_per_kelas.csv')

# 10 besar
df.sort_values('Rata_rata', ascending=False).head(10)[['Nama', 'Kelas', 'Rata_rata', 'Grade']].to_csv('top10_besar.csv')

print("Semua file berhasil diexport!")
```

C. DATASET — nilai_siswa.csv

Download file ini, simpan di folder yang sama dengan script Python.

Nama,Kelas,Matematika,B_Indonesia,B_Ingggris,Informatika,IPA,IPS

Andi Pratama,XI-1,85,78,92,88,75,80
Budi Santoso,XI-1,72,85,80,90,78,82
Citra Dewi,XI-2,90,88,95,92,85,88
Dedi Kusuma,XI-1,,80,75,85,70,72
Eka Fitriani,XI-2,78,92,88,95,80,90
Fajar Hermawan,XI-1,88,75,82,90,78,76
Gita Permata,XI-2,92,85,90,96,88,92
Hadi Nugroho,XI-1,65,70,72,68,60,65
Indah Lestari,XI-2,95,90,96,98,92,94
Joko Susilo,XI-1,70,65,68,72,62,70
Kartika Sari,XI-1,82,88,75,90,80,78
Lina Marlina,XI-2,88,85,90,92,86,84
Mega Putri,XI-1,,78,70,80,72,75
Nanda Pratama,XI-2,80,82,88,85,78,82
Oscar Wijaya,XI-1,75,72,80,78,70,74
Putri Ayu,XI-2,90,92,94,96,88,90
Qori Aini,XI-1,68,72,65,70,62,68
Rizky Ramadhan,XI-2,95,88,92,98,90,88
Sari Dewanti,XI-1,78,85,82,80,75,78
Teguh Prasetyo,XI-2,72,70,68,75,65,70
Umi Kalsum,XI-1,85,80,88,90,82,80
Vino Bastian,XI-2,60,65,62,58,55,60
Wulan Sari,XI-1,92,90,88,94,86,90
Xavier Putra,XI-2,88,82,90,85,80,85
Yuni Rahma,XI-1,76,80,78,82,74,76
Zaidan Malik,XI-2,84,86,85,88,80,82
Ahmad Fauzi,XI-1,70,75,72,68,65,70
Bunga Citra,XI-2,94,90,92,96,88,92
Cahyo Nugroho,XI-1,68,72,70,75,65,68
Dian Sastro,XI-2,86,88,90,92,84,86
Eko Prasetyo,XI-1,82,78,80,85,76,80
Fitriani Dewi,XI-2,90,92,88,94,86,90
Gilang Putra,XI-1,72,68,70,75,65,70
Hana Safira,XI-2,96,92,94,98,90,94
Indra Lesmana,XI-1,78,82,80,85,72,78
Jasmine Azahra,XI-2,88,90,92,95,86,88
Kevin Sanjaya,XI-1,65,70,68,72,60,65
Larasati Putri,XI-2,92,88,90,94,86,90
Maulana Hasan,XI-1,80,75,78,82,72,76
Nabila Putri,XI-2,94,96,92,98,90,92
Oki Setiawan,XI-1,72,68,70,65,62,68
Puspa Indah,XI-2,86,90,88,92,82,86
Qomarul Huda,XI-1,78,82,80,85,76,78
Ratna Kusuma,XI-2,90,88,92,95,86,90
Sandy Pratama,XI-1,68,72,65,70,62,68
Tania Putri,XI-2,92,90,94,96,88,92
Ujang Komarudin,XI-1,82,78,80,85,78,76
Vera Anggraini,XI-2,88,92,90,94,84,88
Wahyu Hidayat,XI-1,70,72,68,75,65,68
Xena Olivia,XI-2,95,90,92,98,88,92
Yoga Pratama,XI-1,75,80,78,82,72,74
Zahra Aulia,XI-2,90,88,92,94,86,90

Catatan: Dataset ini sengaja mengandung missing value, duplikat (Andi Pratama & Citra Dewi muncul 2x), dan outlier (Informatika 101).

D. TANTANGAN LANJUTAN (Jika Selesai Lebih Awal)

Tantangan	Deskripsi
1	Download dataset dari data.go.id (misal: "Data Penduduk") — coba pipeline yang sama
2	Tambahkan histogram untuk distribusi nilai per mapel
3	Analisis korelasi antara 2 mapel dengan <code>df.corr()</code>
4	Ekspor data per kelas ke file terpisah: <code>nilai_XI-1.csv</code> , <code>nilai_XI-2.csv</code>
5	Tambahkan visualisasi heatmap korelasi

```
# Contoh heatmap
import seaborn as sns # pip install seaborn
plt.figure(figsize=(8, 6))
sns.heatmap(df[mapel].corr(), annot=True, cmap='coolwarm')
plt.title('Heatmap Korelasi Antar Mapel')
plt.savefig('heatmap_korelasi.png', dpi=150)
plt.show()
```

E. CHEAT SHEET

Fungsi	Kegunaan
<code>pd.read_csv(file)</code>	Baca CSV
<code>df.head(n)</code>	Lihat n baris pertama
<code>df.info()</code>	Info kolom & tipe data
<code>df.describe()</code>	Statistik deskriptif
<code>df.isnull().sum()</code>	Jumlah missing per kolom
<code>df.duplicated().sum()</code>	Jumlah duplikat
<code>df.drop_duplicates()</code>	Hapus duplikat
<code>df.fillna(x)</code>	Isi missing dengan x
<code>df['kolom'].mean()</code>	Rata-rata kolom
<code>df.groupby('kolom').mean()</code>	Rata-rata per grup
<code>df.sort_values('kolom')</code>	Urutkan
<code>plt.bar()</code> , <code>plt.pie()</code> , <code>plt.scatter()</code>	Grafik
<code>df.to_csv('file.csv')</code>	Ekspor CSV

MGMP Informatika SMAN 6 Cimahi